

Atividade semana 17 ia
Nome: Arthur Saraiva de França 3B;
Nome: Gabriel Alves Costa Dias 3B.

Código completo:

```
import pandas as pd
import numpy as np
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA

# Gerando os dados
np.random.seed(42)

dados = pd.DataFrame({
    "horas_estudo": np.random.randint(1, 6, 50),
    "exercicios": np.random.randint(10, 100, 50),
    "frequencia": np.random.randint(60, 100, 50),
    "participacao": np.random.randint(1, 10, 50)
})

# Criando a nota anterior
dados["nota_anterior"] = (
    dados["horas_estudo"] * 1.5 +
    np.random.normal(0, 1, 50)
)

# ETAPA 1 - Matriz de correlação
print("Matriz de correlação:")
print(dados.corr().round(2))

# Identificando correlações altas
correlacao = dados.corr()

print("\nCorrelações altas:")
for coluna1 in correlacao.columns:
    for coluna2 in correlacao.columns:
        if coluna1 != coluna2:
            valor = correlacao.loc[coluna1, coluna2]

            if abs(valor) >= 0.70:
                print(f"{coluna1} x {coluna2}: {valor:.2f}")

# ETAPA 2 - Redução de colinearidade
# horas_estudo e nota_anterior possuem relação forte.
# Vamos remover nota_anterior para evitar informações redundantes.
```

```

dados_reduzidos = dados.drop(columns=["nota_anterior"])

print("\nVariáveis após a remoção:")
print(dados_reduzidos.columns.tolist())

# ETAPA 3 - Criação de nova feature
dados_reduzidos["engajamento_total"] = (
    dados_reduzidos["frequencia"] +
    dados_reduzidos["participacao"]
)

print("\nDados com a nova feature:")
print(dados_reduzidos.head())

# ETAPA 4 - Aplicação do PCA

# Padronizando os dados
escalador = StandardScaler()
dados_padronizados = escalador.fit_transform(dados_reduzidos)

# Aplicando PCA
pca = PCA(n_components=2)
dados_pca = pca.fit_transform(dados_padronizados)

# Criando um novo DataFrame com os componentes
resultado_pca = pd.DataFrame(
    dados_pca,
    columns=["Componente_1", "Componente_2"]
)

print("\nDados após o PCA:")
print(resultado_pca.head())

# Variância explicada
print("\nVariância explicada por cada componente:")
print(pca.explained_variance_ratio_.round(3))

print("\nVariância total explicada:")
print(round(pca.explained_variance_ratio_.sum(), 3))

```

Perguntas:

Etapa 5 — Análise final

1. Como a seleção de features ajuda na generalização?
Ela remove informações desnecessárias e ajuda o modelo a trabalhar melhor.

2. Por que a colinearidade pode prejudicar modelos?
Porque algumas variáveis trazem informações muito parecidas e podem atrapalhar o modelo.
3. Quando usar PCA?
Quando temos muitas variáveis ou informações repetidas.
4. O modelo apresentou melhora após as mudanças? Por quê?
Pode melhorar porque foram removidas informações desnecessárias e repetidas.
5. Quais variáveis pareciam trazer informações redundantes?
Horas de estudo e nota anterior.
6. A redução de dimensionalidade alterou a interpretação dos dados?
Sim. As variáveis foram transformadas em componentes, dificultando a interpretação individual.
7. Houve impacto no desempenho do modelo?
Pode haver melhora, mas seria necessário comparar os resultados antes e depois para confirmar.